

Análisis, predicción y ejecución automatizada de inversiones en empresas del IBEX 35

Alex De La Haya Gutiérrez



Universitat
Pompeu Fabra
Barcelona

ANÁLISIS, PREDICCIÓN Y EJECUCIÓN AUTOMATIZADA DE INVERSIONES EN EMPRESAS DEL IBEX 35

TRABAJO DE FIN DE GRADO DE
Alex De La Haya Gutiérrez

Director: Vicenç Gómez Cerdà

Grado en Ingeniería Matemática en Ciencia de Datos

Curs 2025-2026



Universitat
Pompeu Fabra
Barcelona

Escola
d'Enginyeria

Agradecimientos

A mi familia y amigos por su apoyo constante y su confianza a lo largo de todo este proceso.

A mi tutor, Vicenç Gómez, por su orientación y ayuda en cada etapa del desarrollo de este trabajo.

A todos los programadores que han contribuido al desarrollo de librerías de código abierto, cuya labor ha hecho posible construir este proyecto sobre una base sólida.

Este trabajo no habría sido posible sin vuestra ayuda. Muchas gracias a todos.

Resumen

Este trabajo desarrolla un sistema automatizado para el análisis, predicción y ejecución de inversiones sobre empresas del IBEX 35. El objetivo principal es evaluar si modelos de aprendizaje automático pueden mejorar o igualar el rendimiento de enfoques tradicionales en la predicción de movimientos bursátiles a corto plazo.

El sistema integra la obtención de datos financieros históricos, la generación de características técnicas, el entrenamiento de modelos predictivos y su explotación mediante una página web, un boletín informativo y un bot de trading. Se comparan distintos enfoques, incluyendo cadenas de Markov, Random Forest, XGBoost, LSTM y GRU, utilizando datos de mercado desde 2006 y un protocolo de evaluación diseñado para evitar fugas temporales.

Además, se incorporan noticias financieras procesadas mediante inteligencia artificial para futuras extensiones. Los resultados se analizan tanto desde una perspectiva predictiva como financiera, evaluando la viabilidad real de las estrategias generadas en condiciones de mercado.

Resum

Aquest treball desenvolupa un sistema automatitzat per a l'anàlisi, la predicció i l'execució d'inversions sobre empreses de l'IBEX 35. L'objectiu principal és avaluar si els models d'aprenentatge automàtic poden millorar o igualar el rendiment dels enfocaments tradicionals en la predicció de moviments borsaris a curt termini.

El sistema integra l'obtenció de dades financeres històriques, la generació de característiques tècniques, l'entrenament de models predictius i la seva explotació mitjançant una pàgina web, un butlletí informatiu i un bot de trading. Es comparen diferents enfocaments, incloent-hi cadenes de Markov, Random Forest, XGBoost, LSTM i GRU, utilitzant dades de mercat des del 2006 i un protocol d'avaluació dissenyat per evitar fuites d'informació temporal.

A més, s'incorporen notícies financeres processades amb intel·ligència artificial per a futures ampliacions. Els resultats s'analitzen tant des d'una perspectiva predictiva com financera, avaluant la viabilitat real de les estratègies generades en condicions de mercat.

Abstract

This thesis develops an automated system for the analysis, prediction, and execution of investments in companies listed on the IBEX 35. The main objective is to assess whether machine learning models can outperform or match traditional approaches in predicting short-term stock market movements.

The system integrates historical financial data collection, technical feature engineering, predictive model training, and deployment through a web platform, a newsletter, and a trading bot. Several approaches are compared, including Markov chains, Random Forest, XGBoost, LSTM, and GRU models, using market data from 2006 onwards and an evaluation protocol specifically designed to prevent temporal data leakage.

In addition, the system incorporates financial news processed with artificial intelligence to enable future extensions. The results are analyzed from both predictive and financial perspectives, evaluating the practical viability of the generated strategies under real market conditions.

Índice

Introducción.....	1
1.1 Contexto.....	1
1.2 Motivación.....	1
1.3 Objetivos.....	1
1.4 Enfoque del proyecto.....	2
Marco Conceptual y Contexto.....	3
2.1 Herramientas y plataformas para la inversión en activos financieros.....	3
2.2 Series temporales financieras y retos de predicción.....	4
2.3 Modelos predictivos para datos financieros.....	4
2.4 De la predicción al rendimiento financiero.....	6
Metodología y desarrollo del sistema.....	7
3.1 Arquitectura general del sistema.....	7
3.2 Datos y fuentes de información.....	8
3.3 Definición de la señal y preparación de datos.....	9
3.4 Modelos predictivos.....	13
3.5 Servicios automatizados del sistema.....	14
3.6 Protocolo experimental.....	18
3.7 Declaración de uso de IA.....	20
Resultados experimentales.....	21
4.1 Resultados predictivos de los modelos.....	21
4.2 Importancia de variables.....	23
4.3 Resultados de la simulación financiera.....	25
4.4 Discusión de los resultados.....	26
Conclusiones.....	27
Trabajo futuro.....	29
Bibliografía.....	30
Apéndice.....	33

Capítulo 1

Introducción

1.1 Contexto

El proyecto se centra en el análisis de activos financieros pertenecientes al IBEX 35, principal índice bursátil español, compuesto por las empresas con mayor capitalización y liquidez del mercado nacional. A partir de datos históricos de cotización, se estudia la evolución temporal de los distintos activos con el objetivo de identificar patrones y tendencias relevantes.

El análisis se orienta principalmente a la predicción de movimientos de mercado, evaluando si el precio de un activo tenderá a subir o bajar en horizontes temporales determinados. Para ello se emplean técnicas de análisis de series temporales y modelos de aprendizaje automático capaces de extraer información a partir de datos financieros históricos.

1.2 Motivación

Este trabajo surge del interés por comprender el funcionamiento de los mercados financieros y analizar hasta qué punto es posible modelar su comportamiento mediante técnicas computacionales. Los mercados constituyen sistemas complejos, dinámicos y altamente influenciados por múltiples factores económicos, sociales y psicológicos, lo que los convierte en un ámbito especialmente atractivo desde el punto de vista analítico y tecnológico.

Además del interés académico, existe una motivación práctica relacionada con la necesidad de preservar y hacer crecer el capital en un contexto económico marcado por la inflación y la pérdida progresiva de poder adquisitivo. En este sentido, el estudio de estrategias de predicción financiera y modelos automatizados de inversión representa una oportunidad para explorar herramientas que puedan contribuir a una mejor toma de decisiones.

Otro de los motivos para desarrollar este proyecto es su potencial de continuidad más allá del propio Trabajo de Fin de Grado. Se trata de un área en constante evolución, con múltiples posibilidades de ampliación y mejora, tanto desde el punto de vista técnico como de investigación. Por ello, el proyecto se plantea no solo como un ejercicio académico, sino como una base sobre la que continuar desarrollando nuevas líneas de trabajo en el futuro.

1.3 Objetivos

El objetivo principal de este trabajo es estudiar si los modelos de aprendizaje automático pueden mejorar las capacidades predictivas de los enfoques tradicionales utilizados en los mercados financieros, o al menos competir con ellos en términos de rendimiento y robustez.

Para ello, se analizan y comparan diferentes aproximaciones, incluyendo modelos estadísticos clásicos, estrategias basadas en reglas simples y técnicas de aprendizaje automático aplicadas a series temporales financieras. A través de esta comparación se pretende evaluar las ventajas, limitaciones y viabilidad real de cada enfoque en escenarios de mercado.

De manera más concreta, los objetivos del proyecto son los siguientes:

- Desarrollar un sistema automatizado y reproducible de análisis financiero que integre la obtención de datos, la generación de predicciones y su explotación mediante una página web, un boletín informativo y un bot de trading.
- Diseñar, implementar y comparar distintos modelos predictivos para activos del IBEX 35, incluyendo métodos clásicos, modelos basados en reglas y modelos de aprendizaje automático.
- Evaluar la viabilidad predictiva y financiera del sistema, analizando si las predicciones sobre la dirección de los activos en horizontes de uno y cinco días permiten obtener una mejora respecto a estrategias de referencia, tanto en métricas de clasificación como en simulaciones de trading con costes de transacción.

1.4 Enfoque del proyecto

Uno de los aspectos relevantes de este trabajo es que no se limita al desarrollo de pruebas aisladas en cuadernos interactivos o experimentos puntuales. El objetivo es construir una estructura completa y organizada, similar a un sistema real de análisis financiero automatizado.

Para ello, se plantea una arquitectura compuesta por diferentes etapas: obtención de datos, procesamiento, entrenamiento de modelos, generación de predicciones y evaluación de resultados. Todo el flujo se diseña de forma que pueda ejecutarse de manera automática y reproducible, facilitando tanto la experimentación como la posible ampliación futura del proyecto.

El proyecto se ha desarrollado con un enfoque de presupuesto cero, utilizando únicamente herramientas gratuitas y de código abierto tanto para el procesamiento de datos como para el entrenamiento y el despliegue de modelos. Esta decisión no solo reduce las barreras de acceso, sino que también favorece la reproducibilidad y la accesibilidad del trabajo para otros estudiantes o investigadores interesados en el área.

Asimismo, el proyecto sigue una filosofía de ciencia abierta, priorizando la claridad en la documentación y la reproducibilidad de los experimentos. De este modo, cualquier persona interesada podría comprender la metodología empleada, replicar los resultados obtenidos o utilizar el sistema como base para futuras investigaciones o desarrollos.

Capítulo 2

Marco Conceptual y Contexto

Este capítulo sitúa el trabajo en su contexto teórico y tecnológico. En primer lugar se describen las herramientas y plataformas existentes para el análisis de activos financieros, identificando sus limitaciones desde el punto de vista de la investigación. A continuación se exponen las características propias de las series temporales financieras que hacen de la predicción un problema especialmente difícil. El capítulo continúa con una revisión de los principales enfoques modelizadores —estadísticos clásicos, métodos de conjunto y redes neuronales recurrentes— para cerrar con una discusión conceptual sobre la evaluación de estrategias predictivas y la brecha entre capacidad estadística y rendimiento financiero real.

2.1 Herramientas y plataformas para la inversión en activos financieros

Actualmente existen numerosas plataformas destinadas al análisis de mercados financieros y al apoyo a la inversión. Entre las más populares destacan Yahoo Finance (Yahoo Finance, 2026) y TradingView (TradingView, 2026), que ofrecen distintos niveles de acceso según el tipo de suscripción.

En sus versiones gratuitas, estas plataformas permiten consultar datos históricos básicos, normalmente con frecuencia diaria o con retrasos de entre 15 y 30 minutos respecto al tiempo real. Además, proporcionan herramientas de visualización de gráficos, incorporación de indicadores técnicos y acceso a noticias financieras relacionadas con los mercados o activos específicos.

Las versiones de pago, que van desde los 10 hasta los 200 euros mensuales, amplían estas funcionalidades mediante acceso a un mayor histórico de datos, actualización en tiempo real, creación de alertas y herramientas avanzadas de análisis técnico. Sin embargo, estas plataformas presentan varias limitaciones desde el punto de vista de la investigación y el desarrollo de sistemas predictivos.

Por un lado, muchas de ellas no ofrecen una API pública completa o presentan restricciones importantes para la extracción automatizada de datos históricos y noticias financieras. Asimismo, la integración directa con brókers suele ser limitada o inexistente, dificultando la automatización completa de estrategias de inversión.

En un nivel más profesional destaca Bloomberg Terminal (Bloomberg L.P., 2026), ampliamente utilizado en entornos financieros institucionales. Esta solución proporciona datos de mercado de alta fidelidad en tiempo real, acceso a noticias financieras, herramientas de análisis cuantitativo, pruebas retrospectivas y soporte para trading algorítmico automatizado. No obstante, su coste es elevado, situándose alrededor de los 30.000 euros anuales, lo que limita su accesibilidad fuera del ámbito profesional o institucional.

A pesar de las amplias funcionalidades disponibles, estas plataformas están orientadas principalmente al análisis financiero tradicional y al trading algorítmico basado en reglas definidas manualmente. Es importante diferenciar este enfoque del uso de técnicas de aprendizaje automático. Las pruebas retrospectivas tradicionales consisten en evaluar estrategias predefinidas utilizando datos históricos —por ejemplo, mediante reglas fijas de compra y venta basadas en indicadores técnicos—. En cambio, los modelos de aprendizaje automático buscan aprender patrones complejos directamente a partir de los datos para realizar predicciones futuras, adaptándose dinámicamente a nuevas condiciones del mercado.

Las plataformas analizadas no proporcionan de forma integrada herramientas completas para el entrenamiento, validación y despliegue de modelos de aprendizaje automático. Incluso en entornos

avanzados como Bloomberg Terminal, el desarrollo de modelos predictivos suele realizarse externamente mediante lenguajes y bibliotecas especializadas, como Python junto con frameworks de ciencia de datos y aprendizaje automático (Pedregosa et al., 2011). Posteriormente, los resultados deben reintegrarse en la plataforma o conectarse directamente con brókers para ejecutar operaciones. Esta situación justifica el interés en desarrollar soluciones específicas que integren obtención de datos, análisis financiero y modelos de aprendizaje automático dentro de un mismo entorno.

2.2 Series temporales financieras y retos de predicción

La predicción de series temporales financieras constituye una de las principales aplicaciones del análisis cuantitativo en mercados financieros. En este contexto, una serie temporal puede definirse como una secuencia de observaciones ordenadas cronológicamente, donde cada valor depende potencialmente de los anteriores. En finanzas, ejemplos habituales son el precio de cierre de una acción, el volumen negociado o los retornos de un activo.

El precio de los activos financieros suele considerarse una serie no estacionaria, ya que sus propiedades estadísticas cambian con el tiempo debido a factores económicos, políticos o sociales. Esta no estacionariedad dificulta el modelado y la predicción directa de los precios. Por este motivo, gran parte de la literatura trabaja con los retornos financieros en lugar de los precios absolutos, ya que los retornos presentan un comportamiento más cercano a la estacionariedad y facilitan el uso de modelos estadísticos y de aprendizaje automático.

En este contexto, el objetivo del trabajo no es predecir con precisión el precio futuro de los activos, sino evaluar si existe una señal débil que permita anticipar la dirección del movimiento en horizontes cortos. Por ello, el problema se formula como una tarea de clasificación binaria sobre el signo del retorno futuro, y no como una regresión directa sobre precios.

En las series temporales financieras resulta especialmente relevante el estudio de la autocorrelación, es decir, la dependencia existente entre valores observados en distintos instantes temporales. Analizar si los valores pasados contienen información útil para predecir los futuros es fundamental para determinar la aplicabilidad de determinados modelos predictivos. Lo y MacKinlay (1988) demostraron que los precios de las acciones no siguen exactamente un paseo aleatorio (*random walk*), aunque las desviaciones observadas son pequeñas y su explotabilidad práctica es limitada.

La predicción de series temporales financieras presenta una dificultad adicional derivada de la hipótesis del mercado eficiente (Fama, 1970). Esta hipótesis establece que el precio de los activos refleja toda la información disponible en el mercado, por lo que resulta extremadamente difícil obtener ventajas predictivas consistentes utilizando únicamente información histórica. En consecuencia, los movimientos futuros del mercado presentan un elevado componente aleatorio y una baja relación señal-ruido, lo que limita la capacidad predictiva de muchos modelos.

2.3 Modelos predictivos para datos financieros

La literatura sobre predicción financiera cuantitativa ha desarrollado una amplia variedad de enfoques, que van desde los modelos estadísticos clásicos de series temporales hasta las arquitecturas de aprendizaje profundo más recientes. Cada familia de modelos refleja hipótesis distintas sobre la estructura de dependencia de los datos financieros: los métodos clásicos asumen formas de

dependencia paramétrica y bien caracterizadas, mientras que los modelos de aprendizaje automático buscan aprender esas estructuras directamente a partir de los datos.

Entre los enfoques tradicionales para la predicción de series temporales destacan los modelos ARIMA (*Autoregressive Integrated Moving Average*). Estos modelos combinan componentes autorregresivos y de medias móviles para capturar dependencias temporales en la serie, y han sido ampliamente utilizados en finanzas para la predicción de precios y volatilidad (Box et al., 2015).

Otro enfoque clásico son las cadenas de Markov, en las que el sistema se modela mediante un conjunto finito de estados y probabilidades de transición entre ellos. La hipótesis fundamental es que el estado futuro depende únicamente del estado actual y no de toda la trayectoria previa. En finanzas, los modelos de Markov se han utilizado para modelar cambios de régimen de mercado, tendencias alcistas y bajistas o variaciones en volatilidad (Hamilton, 1989).

Los modelos basados en árboles de decisión han ganado popularidad en el ámbito financiero debido a su robustez y capacidad para modelar relaciones no lineales. Aunque estos modelos no incorporan de forma explícita el orden temporal de los datos, pueden utilizar información histórica mediante ingeniería de características, incluyendo retardos, medias móviles o indicadores técnicos como variables de entrada.

Random Forest (Breiman, 2001) es un método de aprendizaje ensamblado que combina múltiples árboles de decisión generados a partir de subconjuntos aleatorios de datos y variables. La predicción final se obtiene mediante votación o promedio entre los distintos árboles, lo que reduce el sobreajuste y mejora la capacidad de generalización. En finanzas se ha utilizado para la predicción de retornos y movimientos de mercado debido a su estabilidad frente al ruido característico de los datos financieros (Krauss et al., 2017).

XGBoost (Chen y Guestrin, 2016) es una técnica de potenciación de gradiente basada en árboles de decisión que construye modelos secuencialmente, corrigiendo en cada iteración los errores cometidos por los árboles anteriores. Este enfoque permite capturar relaciones complejas y suele ofrecer un alto rendimiento predictivo. XGBoost ha sido ampliamente empleado en problemas financieros, especialmente en predicción de precios y clasificación de tendencias bursátiles (Krauss et al., 2017).

Las redes neuronales recurrentes (RNN) están diseñadas específicamente para procesar datos secuenciales, ya que mantienen información de estados anteriores mediante conexiones recurrentes. Esto las hace especialmente adecuadas para el análisis de series temporales financieras.

Sin embargo, las RNN tradicionales presentan dificultades para capturar dependencias a largo plazo debido a problemas como el desvanecimiento del gradiente. Para solucionar estas limitaciones surgieron arquitecturas más avanzadas: las redes LSTM (*Long Short-Term Memory*) incorporan mecanismos de memoria y compuertas que permiten conservar información relevante durante periodos prolongados (Hochreiter y Schmidhuber, 1997). De forma similar, las redes GRU (*Gated Recurrent Unit*) simplifican esta arquitectura reduciendo el número de parámetros y el coste computacional (Cho et al., 2014). Ambos modelos reciben habitualmente como entrada ventanas temporales de observaciones pasadas para predecir valores futuros de la serie.

En el ámbito financiero, LSTM y GRU se han utilizado ampliamente para la predicción de precios, retornos y volatilidad debido a su capacidad para capturar patrones temporales complejos (Fischer y Krauss, 2018).

No obstante, el uso de modelos de aprendizaje profundo en finanzas presenta ciertas dificultades relacionadas con la disponibilidad limitada de datos. Aunque las series financieras contienen miles de observaciones, esta cantidad sigue siendo reducida en comparación con otros dominios del aprendizaje profundo, donde suelen emplearse millones de ejemplos. Como consecuencia, estos modelos pueden aprender ruido o variaciones aleatorias en lugar de patrones generales. López de Prado (2018)

recomienda complementar las redes neuronales con ingeniería de características, incorporando indicadores técnicos, variables macroeconómicas o transformaciones estadísticas que faciliten el aprendizaje y mejoren la capacidad de generalización del modelo.

En general, los modelos estadísticos clásicos destacan por su interpretabilidad y por requerir una menor cantidad de datos para su entrenamiento. Sin embargo, presentan limitaciones para capturar relaciones no lineales complejas presentes en los mercados financieros. Por otro lado, los métodos de aprendizaje automático ofrecen una mayor capacidad de modelado y pueden detectar patrones más sofisticados, aunque requieren más datos, mayor capacidad computacional y presentan una interpretabilidad más reducida.

2.4 De la predicción al rendimiento financiero

La construcción de un modelo predictivo es solo el primer paso hacia un sistema de inversión algorítmica operativo. Entre la capacidad estadística de un clasificador y su rentabilidad financiera real existe una brecha conceptual y práctica que conviene entender antes de interpretar los resultados experimentales.

En un problema de clasificación binaria estándar, el modelo asume que un acierto en la dirección del precio tiene el mismo valor sin importar la magnitud del movimiento. Sin embargo, en el entorno operativo, el impacto económico es asimétrico y depende de la intensidad de dichas variaciones. Un modelo puede mantener una precisión elevada mediante aciertos en periodos de baja volatilidad, pero resultar económicamente inviable si sus escasos fallos se concentran en giros bruscos del mercado.

A esta asimetría se suman las fricciones del mercado real, como los costes de transacción, comisiones y el deslizamiento de precios. Un rendimiento estadístico sobresaliente puede evaporarse por completo si el margen de ganancia por operación es inferior a estos costes. López de Prado (2018) advierte que evaluar estrategias cuantitativas basándose exclusivamente en métricas matemáticas genera falsos descubrimientos. Es necesario complementar la validación estadística con un *backtesting* riguroso que incorpore costes y medidas de rendimiento ajustadas al riesgo como criterio final de viabilidad.

Capítulo 3

Metodología y desarrollo del sistema

Este capítulo describe el sistema desarrollado, desde su arquitectura general hasta los detalles de implementación de cada componente. La estructura sigue el flujo natural del sistema: primero se presenta la arquitectura de conjunto, luego las fuentes de datos y su preprocesamiento, a continuación los modelos y los servicios automatizados que consumen sus predicciones, y finalmente el protocolo experimental empleado para evaluarlos.

3.1 Arquitectura general del sistema

La Figura 1 muestra un esquema general de la arquitectura de las automatizaciones desarrolladas en el proyecto. El sistema parte de dos fuentes principales de información: los datos de mercado y las noticias financieras. Ambos flujos convergen en una base de datos centralizada, desde la cual se ejecutan los modelos de predicción. Finalmente, las predicciones generadas pueden ser consumidas por distintos servicios: un bot de trading, una página web de visualización y un boletín informativo automatizado.




Figura 1. Diagrama de arquitectura del sistema automatizado.

La arquitectura del sistema se diseñó siguiendo una separación clara de responsabilidades en bloques independientes. Cada tarea del pipeline se ejecuta de forma desacoplada mediante automatizaciones gestionadas con GitHub Actions (GitHub Inc., 2026). Este enfoque mejora la robustez y mantenibilidad del sistema, ya que un fallo en una etapa concreta no interrumpe necesariamente el resto del flujo de trabajo.

Uno de los bloques principales corresponde a la gestión de datos de mercado. El objetivo de esta etapa es construir y mantener una base de datos histórica de información bursátil fiable y actualizada. Las automatizaciones verifican que tanto el mercado español como el estadounidense hayan cerrado antes de actualizar los registros diarios, evitando almacenar valores incompletos debido a sesiones todavía abiertas.

Los datos actualizados se almacenan inicialmente en una base de datos en la nube mediante Supabase (Supabase Inc., 2026), utilizada como punto central de acceso para los distintos servicios del sistema. Adicionalmente, de forma periódica se realiza una migración hacia una base de datos local SQLite que

contiene el histórico completo de mercado. Esta copia local se emplea principalmente para tareas de entrenamiento de modelos, análisis exploratorio y experimentación, evitando depender continuamente de descargas externas.

El bloque de predicción constituye el núcleo del sistema automatizado. Una vez entrenados los modelos, las automatizaciones recuperan de la base de datos en la nube las observaciones más recientes de cada activo para generar nuevas predicciones. En este proceso es necesario considerar ventanas temporales amplias —de unas 300 observaciones por activo— ya que muchas de las variables utilizadas requieren información histórica suficiente para ser calculadas correctamente.

3.2 Datos y fuentes de información

En esta sección se describen tanto los datos recopilados externamente como los datos generados durante el desarrollo del sistema. El objetivo es disponer de información histórica financiera, contextual y derivada que permita entrenar, evaluar y desplegar modelos predictivos sobre activos del IBEX 35.

Series temporales financieras

Se recopilaron series temporales diarias correspondientes a los distintos activos financieros del IBEX 35. Cada registro incluye el precio de apertura, el precio máximo alcanzado durante la sesión, el precio mínimo, el precio de cierre y el volumen de negociación asociado al activo en dicha jornada. Estos valores constituyen la base principal para la generación de características y el entrenamiento de modelos predictivos.

Los activos considerados corresponden a las compañías pertenecientes al IBEX 35 durante el período de estudio: ACS, Acerinox, Aena, Amadeus IT Group, Acciona, Acciona Energía, BBVA, Bankinter, CaixaBank, Cellnex Telecom, Colonial, Endesa, Enagás, Fluidra, Ferrovial, Grifols, IAG, Iberdrola, Inditex, Logista, Mapfre, Merlin Properties, ArcelorMittal, Naturgy, Puig, Redeia, Banco Sabadell, Banco Santander, Telefónica y Unicaja Banco. El universo fijado presenta un potencial sesgo de supervivencia, ya que incluye únicamente empresas que han permanecido en el índice a lo largo del período; compañías que fueron excluidas o entraron en concurso de acreedores no están representadas.

El conjunto de datos contiene 129.910 registros, comprendidos entre enero de 2006 y abril de 2026. La fecha de inicio no es arbitraria: aunque algunas compañías disponen de datos anteriores, antes de 2006 existen inconsistencias relevantes en determinados activos, como fechas faltantes, volúmenes negativos o nulos, precios erróneos y discontinuidades temporales. Por este motivo, se estableció enero de 2006 como punto inicial a partir del cual los datos presentan suficiente calidad y consistencia.

Además de las compañías individuales, se recopilaron indicadores de mercado e índices de referencia como el IBEX 35, el S&P 500 y el índice de volatilidad VIX. El histórico de estos índices está disponible desde fechas anteriores a 2006; sin embargo, no fue necesario utilizar todo el histórico disponible, ya que únicamente se requiere una ventana temporal previa suficiente para construir características basadas en ventanas móviles amplias. Por ejemplo, la variable Percentil VIX (250) necesita al menos 250 sesiones anteriores para calcularse correctamente.

Todos estos datos fueron obtenidos mediante la librería `yfinance` (Ranaroussi, 2023), que actúa como interfaz de acceso a Yahoo Finance.

El histórico recopilado abarca distintos contextos y ciclos de mercado, incluyendo periodos alcistas, fases de alta volatilidad y crisis financieras relevantes. Esto permite que los modelos aprendan patrones asociados a diferentes condiciones económicas, mejorando su capacidad de generalización y adaptación ante escenarios diversos.

Noticias financieras

Adicionalmente, se recopiló un conjunto de noticias financieras procedentes del diario económico Expansión, concretamente de las secciones de economía, mercados, empresas y ahorro, abarcando el período comprendido desde enero de 2026. Aunque actualmente estos datos NO se incorporan directamente al entrenamiento de los modelos, forman parte de la infraestructura del sistema y permiten futuras extensiones relacionadas con análisis de sentimiento y modelado multimodal.

Para cada noticia se almacenan los siguientes campos originales: título, cuerpo, sección, URL y fecha de publicación. A partir de estos datos también se generan automáticamente varios atributos derivados: la categoría de la noticia (específica de compañía, macroeconómica, sentimiento de mercado o ruido general), la relevancia estimada en el rango $[0, 1]$, el sentimiento asociado (positivo, negativo o neutro) y las compañías mencionadas.

Boletín informativo

El sistema también almacena información asociada al servicio de boletín de noticias, incluyendo fecha de suscripción y dirección de correo electrónico. Estos datos permiten gestionar el envío automatizado de predicciones y alertas generadas por el sistema.

Predicciones

A partir de los datos recopilados y las características derivadas, el sistema genera predicciones para cada activo financiero. Para cada combinación de activo, fecha y modelo se almacena una predicción binaria indicando si el precio del activo aumentará durante los próximos h días, así como la probabilidad asociada a dicha predicción. Estas salidas son utilizadas para inferencia en producción y generación de recomendaciones.

3.3 Definición de la señal y preparación de datos

Definición de la señal

La señal se construye a partir del retorno logarítmico futuro del activo. Para cada día t , se calcula el retorno logarítmico entre el precio de cierre en t y el precio de cierre en $t + h$, donde h representa el horizonte temporal considerado. El retorno logarítmico se define como:

$$r_{t,h} = \ln \left(\frac{P_{t+h}}{P_t} \right)$$

donde P_t es el precio de cierre del activo en el instante t y P_{t+h} es el precio de cierre tras un horizonte temporal h . A partir de este valor, la variable objetivo se define de forma binaria:

$$y_t = \begin{cases} 1 & \text{si } r_{t,h} > 0 \\ 0 & \text{en caso contrario} \end{cases}$$

Una señal igual a 1 indica que el precio futuro es superior al precio actual. Los horizontes considerados en este trabajo son de 1 y 5 días. El horizonte de 1 día permite capturar movimientos de muy corto plazo y evaluar la capacidad del modelo para anticipar la dirección inmediata del mercado. Por su parte, el horizonte de 5 días busca modelar tendencias ligeramente más estables y menos sensibles al ruido diario, aproximándose al comportamiento semanal del activo.

Exploración de datos

La predicción de series financieras constituye un problema especialmente complejo debido a la propia naturaleza de los retornos bursátiles. En particular, los retornos logarítmicos suelen presentar un comportamiento próximo al de un proceso de ruido blanco, caracterizado por una elevada aleatoriedad y una baja dependencia temporal entre observaciones consecutivas. Esto implica que los movimientos pasados del mercado contienen una cantidad limitada de información útil para anticipar movimientos futuros (Fama, 1970).

La Figura 2 muestra la evolución temporal de los retornos logarítmicos de un activo representativo del IBEX 35. Puede observarse que la serie presenta oscilaciones rápidas y aparentemente irregulares, sin patrones visuales persistentes ni tendencias fácilmente identificables, lo que evidencia el elevado nivel de ruido presente en la señal financiera.

El análisis de autocorrelación representado en la Figura 3 refuerza esta idea. Los coeficientes de autocorrelación para distintos retardos se mantienen próximos a cero, lo que indica una débil relación lineal entre los retornos actuales y los retornos pasados, en línea con los resultados de Lo y MacKinlay (1988). En consecuencia, resulta difícil extraer patrones temporales robustos únicamente a partir de la evolución histórica del precio.




Figura 2. Evolución temporal de los retornos logarítmicos diarios de un activo representativo del IBEX 35.




Figura 3. Función de autocorrelación (ACF) de los retornos logarítmicos diarios.

Estas características suponen un desafío importante para los modelos de aprendizaje automático. En problemas donde la señal contiene una alta proporción de ruido y una estructura temporal limitada, la capacidad predictiva de los modelos tiende a reducirse considerablemente (López de Prado, 2018).

Feature engineering

Con el objetivo de mejorar la capacidad predictiva de los modelos y facilitar el aprendizaje de patrones temporales consistentes, se llevó a cabo un proceso de ingeniería de características (*feature engineering*) sobre las series financieras originales. Este proceso busca transformar los datos brutos en representaciones más informativas, estables y comparables entre distintos activos.

En lugar de utilizar precios absolutos o retornos simples, se emplearon retornos logarítmicos. Esta transformación permite representar las variaciones relativas del precio de forma más consistente a lo largo del tiempo, además de reducir parcialmente los problemas asociados a las diferencias de escala entre activos. Los retornos logarítmicos presentan propiedades especialmente útiles en series financieras, como una mayor simetría estadística y la aditividad temporal, lo que facilita tanto el análisis como el aprendizaje por parte de los modelos.

Las características utilizadas fueron comunes para todos los modelos desarrollados, con la excepción de la variable correspondiente al día de la semana. En el caso de las redes neuronales recurrentes, esta característica se representó mediante una codificación sinusoidal, con el objetivo de reflejar la naturaleza cíclica y continua del calendario semanal. De este modo, el modelo puede interpretar que

días consecutivos como viernes y lunes mantienen una proximidad temporal, evitando discontinuidades artificiales derivadas de una codificación categórica tradicional.

Las variables generadas se construyeron principalmente a partir de retornos, ratios, diferencias y transformaciones normalizadas, evitando el uso directo de magnitudes absolutas como precios o volúmenes sin procesar. Esto resulta especialmente importante en modelos basados en árboles de decisión, ya que cambios bruscos en escala o distribución pueden alterar los puntos de partición aprendidos durante el entrenamiento y deteriorar el rendimiento fuera de muestra (López de Prado, 2018).

Además de variables intrínsecas de cada activo, se incorporaron características relacionadas con el contexto de mercado. En particular, se añadieron indicadores procedentes del IBEX 35 y del mercado estadounidense, debido a su influencia sobre la evolución de los mercados europeos. Para ello, fue necesario alinear calendarios bursátiles distintos, ya que algunos mercados permanecen cerrados en fechas diferentes. En esos casos, se aplicó un proceso de relleno hacia adelante sobre las variables del mercado externo y, cuando correspondía, se sustituyeron movimientos inexistentes por retornos nulos, evitando introducir discontinuidades artificiales en las series temporales.

Durante el preprocesamiento también se eliminaron variables que pudieran introducir sesgos no deseados en el entrenamiento, entre ellas identificadores explícitos como la fecha exacta o el nombre de la compañía, así como variables intermedias utilizadas únicamente para construir nuevas características. El objetivo es evitar que el modelo aprenda patrones específicos de empresas concretas o dependencias temporales espurias que no necesariamente se mantendrán en el futuro.

Por último, todas las características temporales se construyeron respetando estrictamente la causalidad temporal. Cada ventana de datos utiliza únicamente información disponible hasta el instante actual, sin incorporar datos futuros en ninguna transformación o cálculo. Este aspecto es fundamental en problemas financieros, ya que cualquier filtración de información futura puede producir estimaciones irreales del rendimiento y comprometer la capacidad de generalización del modelo en escenarios reales (López de Prado, 2018).

La Tabla 1 presenta un resumen de las características utilizadas y su definición correspondiente.

Tabla 1. Características generadas mediante feature engineering. Los números entre paréntesis indican el tamaño de la ventana temporal empleada en cada cálculo.

Característica	Explicación breve	Característica	Explicación breve
Logaritmo retorno (1;5;10;20)	Retorno logarítmico en distintos horizontes temporales	Retorno intradía (1)	Diferencia entre precio de cierre y apertura normalizada
Volatilidad (5)	Desviación estándar de retornos en ventana de 5 días	Cuerpo	Tamaño absoluto del cuerpo de la vela japonesa
Ratio volatilidad (5/20)	Cociente entre volatilidades de corto y largo plazo	Mecha superior	Proporción de la mecha superior respecto al rango total
Rango verdadero medio (14)	Average True Range; medida de volatilidad intradía	Mecha inferior	Proporción de la mecha inferior respecto al rango total
Ratio media móvil (5/20;10/50)	Cociente entre medias móviles de distintos periodos	Hueco	Diferencia entre apertura del día y cierre del día anterior
MACD (12,26,9)	Diferencia entre medias exponenciales de distinta longitud	Día de la semana	Variable cíclica (codificación sinusoidal en RNN)
Bandas de Bollinger (20)	Distancia del precio respecto a la banda superior e inferior	Amplitud del mercado (1;10)	Proporción de valores del IBEX 35 con retorno positivo
Pendiente (10)	Pendiente de la regresión lineal del precio sobre una ventana de 10 días	Retorno relativo IBEX (5;20)	Diferencia entre retorno del activo y retorno del índice
Distancia al máximo (10;20)	Distancia relativa al máximo de la ventana	Volatilidad IBEX (10)	Desviación estándar de retornos del IBEX 35
Distancia al mínimo (10;20)	Distancia relativa al mínimo de la ventana	Ratio volatilidad IBEX (10/60)	Cociente de volatilidades del IBEX 35 en distintos horizontes
RSI (14)	Índice de fuerza relativa en ventana de 14 días	Volatilidad relativa IBEX (20)	Cociente entre volatilidad del activo y la del índice
Ratio volumen (1/5;1/20)	Cociente entre el volumen reciente y el volumen promedio	Volatilidad S&P (20)	Desviación estándar de retornos del S&P 500
Pendiente del OBV (10)	Tendencia del volumen on-balance en una ventana de 10 días	Ratio volatilidad S&P (20;100)	Cociente entre volatilidades del S&P 500 en distintos horizontes
Iliquidez Amihud (10)	Ratio de iliquidez de Amihud (2002): impacto del precio por unidad de volumen	Cambio VIX (5)	Variación del índice de volatilidad implícita en 5 días
Retornos autocorrelacionados (10)	Autocorrelación de los retornos en una ventana de 10 días	Percentil VIX (250)	Percentil del VIX actual respecto al histórico de los últimos 250 días

3.4 Modelos predictivos

Se evalúan cinco familias de modelos que representan distintas hipótesis sobre la estructura de los datos financieros: cadenas de Markov, Random Forest, XGBoost, LSTM y GRU. En todos los casos el problema se formula como clasificación binaria (subida/bajada) y la salida es una probabilidad $P(\text{subida} | X_t)$; la predicción discreta se obtiene aplicando un umbral de 0,5. La Tabla 2 resume los inputs, outputs e hiperparámetros principales de cada modelo.

Tabla 2. Resumen de los modelos implementados: entradas, salidas e hiperparámetros principales.

Modelo	Entradas	Salidas	Hiperparámetros principales
Markov	Logaritmo retorno (1)	P(subida)	Estados = 3, Orden = 1, $\alpha = 1$
RF	41 variables	P(subida)	Estimadores = 500, Máxima profundidad = 5, Máximo de variables x división = 0.3, Mínimo de muestras x hoja = 50
XGB	41 variables	P(subida)	Estimadores = 300, Máxima profundidad = 3, Mínimo peso de un nodo hijo = 100, Submuestreo = 0.7, Parada temprana, Tasa de aprendizaje = 0.05
LSTM	41 variables x ventana temporal de 20 días	P(subida)	Capas recurrentes = 1, Unidades ocultas = 64, Dropout = 0.3, Parada temprana, Tasa de aprendizaje = 0.0003
GRU	41 variables x ventana temporal de 20 días	P(subida)	Capas recurrentes = 1, Unidades ocultas = 64, Dropout = 0.3, Parada temprana, Tasa de aprendizaje = 0.0003

El modelo de Markov discretiza el espacio de retornos en 3 estados que representan movimientos bajistas, neutros y alcistas. El estado actual queda determinado por el retorno logarítmico del día anterior. A partir del conjunto de entrenamiento se estima la matriz de transición como la frecuencia empírica de movimientos alcistas en cada estado. El modelo emplea solo dos clases de predicción: subida o bajada.

Random Forest combina 500 árboles de decisión poco profundos (máx 5) entrenados sobre subconjuntos aleatorios de datos y variables (30% de características por partición). La restricción explícita de la complejidad individual de cada árbol —junto con el límite de 50 observaciones mínimas por hoja— favorece la generalización y previene el ajuste excesivo a patrones espurios en datos financieros de alta varianza.

Los árboles de XGBoost son muy superficiales (máx 3) para que la complejidad emerja de la acumulación de muchos estimadores débiles. Se emplea parada temprana (*early stopping*) para determinar el número óptimo de iteraciones y evitar el sobreajuste.

Las redes LSTM y GRU reciben como entrada una ventana temporal de 20 observaciones pasadas expresadas como secuencias de las 41 características. Se utilizan arquitecturas deliberadamente compactas —una única capa recurrente con capacidad de representación moderada, *dropout* y parada temprana— para limitar la flexibilidad del modelo y priorizar la estabilidad fuera de muestra sobre señales de baja relación señal-ruido.

3.5 Servicios automatizados del sistema

Procesamiento de noticias

El sistema incorpora un módulo de procesamiento automático de noticias financieras basado en técnicas de inteligencia artificial generativa. Su objetivo principal es transformar información textual no estructurada en señales útiles para el análisis financiero y la toma de decisiones.

Para ello, se emplea un agente especializado basado en modelos de lenguaje de gran tamaño, encargado de analizar cada noticia y extraer información relevante mediante tres tareas principales: categorización temática, identificación de compañías mencionadas y análisis de sentimiento.

Se utiliza un enfoque híbrido para calcular la relevancia de las noticias. Por un lado, el modelo de lenguaje proporciona una interpretación semántica y contextual del contenido. Por otro, se incorporan reglas heurísticas basadas en palabras clave y eventos financieros relevantes, como dividendos, OPAs, publicación de resultados, adquisiciones o cambios regulatorios. Esta combinación entre técnicas basadas en inteligencia artificial y reglas explícitas permite construir un sistema más robusto, interpretable y controlable que un enfoque exclusivamente basado en inteligencia artificial generativa.

El modelo utilizado para las tareas de procesamiento es openai/gpt-oss-120b (OpenAI, 2025), ejecutado a través de la infraestructura de inferencia de Groq (Groq, 2026). Se trata de un modelo de lenguaje de gran tamaño optimizado para tareas de razonamiento y comprensión contextual, capaz de procesar información financiera compleja y generar respuestas estructuradas de forma eficiente.

Durante el desarrollo se tuvieron en cuenta diversas limitaciones técnicas y operativas. El uso de planes gratuitos tanto para los modelos de inteligencia artificial como para GitHub Actions introduce restricciones de límite de frecuencia y de tiempo de ejecución. Para mejorar la eficiencia, se optó por agrupar aproximadamente diez noticias en una única llamada al modelo en lugar de procesarlas individualmente. Esta decisión busca un equilibrio entre rendimiento y calidad de las respuestas: procesar una noticia por llamada resultaba ineficiente en términos de coste temporal, mientras que incluir demasiadas noticias en una misma petición puede degradar la calidad del análisis debido a limitaciones de contexto del modelo.

Página web

La solución desarrollada se ha desplegado mediante GitHub Pages como una aplicación web estática basada en HTML, CSS y JavaScript. La página incorpora elementos dinámicos gracias a la actualización automática de las predicciones bursátiles y a la integración de noticias financieras en tiempo real.

Como se ilustra en la Figura 4, en la parte principal de la interfaz se muestran las predicciones correspondientes a la siguiente sesión bursátil. Cada activo aparece representado mediante una tarjeta individual que indica la dirección esperada del movimiento y la probabilidad asociada. Las tarjetas utilizan un código de colores para facilitar la interpretación: los tonos verdes representan expectativas alcistas, mientras que los tonos rojos indican una posible caída del activo.

La interfaz también permite interactuar con cada tarjeta. Al seleccionar un activo, el usuario accede a una vista más detallada en la que puede consultar la cotización actual y visualizar distintos gráficos

financieros junto con indicadores técnicos configurables. De este modo, la plataforma no solo proporciona una señal de predicción, sino también herramientas adicionales para contextualizarla.

En la parte inferior de la página se incorpora un panel de noticias financieras en directo inspirado en los cintillos informativos utilizados en televisión. Las noticias se muestran de forma continua mediante un desplazamiento horizontal automático, lo que permite consultar titulares recientes sin abandonar la página principal.

La inclusión de este apartado responde a una necesidad complementaria a las predicciones generadas por el modelo. Aunque los modelos de aprendizaje automático son capaces de captar patrones complejos del mercado, existen acontecimientos repentinos —anuncios políticos inesperados, conflictos internacionales o eventos extraordinarios— que pueden provocar movimientos intradía abruptos fuera del alcance predictivo del sistema. La integración de noticias en tiempo real aporta contexto adicional y mejora la capacidad del usuario para interpretar correctamente la situación del mercado.

La web también describe la arquitectura general del modelo empleado, incluyendo el horizonte temporal de predicción, el período histórico utilizado para el entrenamiento y el conjunto de variables consideradas. Por último, se incluye una declaración de responsabilidad y transparencia donde se detallan las limitaciones del sistema y se recuerda que las predicciones generadas no constituyen asesoramiento financiero, sino una herramienta de apoyo a la toma de decisiones.




Figura 4. Interfaz principal de la página web.

Boletín informativo

El sistema incorpora un servicio de envío automático de correos electrónicos con el objetivo de facilitar un seguimiento diario de las predicciones generadas por el modelo. Cada mañana, los usuarios suscritos reciben un informe resumido con la información más relevante de la sesión anterior.

Como se observa en la Figura 5, el correo sigue una estructura clara y visualmente organizada. En primer lugar, se muestran las tres predicciones en las que el modelo presenta un mayor nivel de confianza relativa. Tras este bloque inicial se incluye un listado con las diez noticias financieras más relevantes publicadas durante el día anterior, ordenadas según su relevancia estimada. Cada noticia incorpora un breve resumen descriptivo y un enlace directo al artículo original.

El envío de los informes se realiza mediante el servidor SMTP de Gmail, lo que permite automatizar la distribución diaria de manera fiable. Asimismo, el sistema soporta listas de distribución de hasta 500 destinatarios. Las direcciones de correo de los usuarios suscritos se almacenan en una base de

datos en la nube, desde la cual se gestiona de forma centralizada el proceso de suscripción y envío de notificaciones.

Con el objetivo de mantener la coherencia visual entre la plataforma web y el sistema de notificaciones, el diseño del correo conserva los principales elementos gráficos de la aplicación, incluyendo la tipografía, la paleta de colores y la disposición general de la información. La implementación se ha adaptado a las limitaciones propias del formato HTML en clientes de correo electrónico, donde determinados componentes interactivos no pueden reproducirse de manera equivalente, priorizando la legibilidad y la correcta visualización en distintos dispositivos.



Figura 5. Ejemplo del boletín informativo diario.

Bot de trading

La automatización de la ejecución de operaciones se ha desarrollado mediante un bot de trading encargado de interpretar las predicciones generadas por el modelo y transformarlas en órdenes reales de mercado. Uno de los principales condicionantes del desarrollo fue la elección del bróker. En el caso del mercado español, muchos brókers tradicionales presentan limitaciones importantes en cuanto a automatización y acceso programático. Dentro de las alternativas disponibles, Interactive Brokers

(Interactive Brokers, 2026) fue la opción que mejor se adaptó a las necesidades del proyecto, principalmente por la estabilidad de su infraestructura y por las posibilidades de automatización que ofrece.

El bot se conecta localmente al puerto habilitado por la aplicación del bróker una vez el usuario ha iniciado sesión y se ha autenticado correctamente. A partir de esa conexión, el sistema puede consultar información de mercado, obtener el estado de la cuenta y enviar órdenes de compra o venta de forma programática. Se implementó además una lógica de reconexión automática para gestionar posibles interrupciones de la conexión debidas a reinicios de la plataforma, problemas de red o desconexiones temporales.

El bot lee diariamente las predicciones generadas por el modelo y ejecuta las operaciones correspondientes al inicio de la sesión bursátil. Todas las posiciones abiertas reciben el mismo peso dentro de la cartera, con el objetivo de mantener una estrategia sencilla y evitar introducir sesgos adicionales en la asignación de capital.

La automatización del sistema se gestiona mediante una tarea programada de PowerShell. Cada día laborable, el proceso se inicia automáticamente a las 9:00 de la mañana (hora española), coincidiendo con la apertura del mercado, y finaliza a las 16:45, quince minutos antes del cierre de la sesión bursátil. Para las pruebas iniciales se utilizó una cuenta de simulación con un capital ficticio de 100.000 euros proporcionado por el bróker, lo que permite validar el funcionamiento del sistema en condiciones similares a las reales sin asumir riesgo financiero.

3.6 Protocolo experimental

Esta sección describe el procedimiento completo de entrenamiento y evaluación utilizado para obtener los resultados del Capítulo 4.

Entrenamiento

En problemas de predicción financiera basados en series temporales resulta fundamental respetar el orden cronológico de los datos durante todo el proceso de entrenamiento y validación. De lo contrario, pueden producirse fugas de información que generan resultados artificialmente optimistas que no se mantienen cuando el modelo se utiliza en condiciones reales (López de Prado, 2018).

Existen dos enfoques habituales para construir las ventanas temporales de entrenamiento: ventana deslizante y ventana expansiva. En el primer caso, la ventana de entrenamiento mantiene un tamaño fijo y se desplaza en el tiempo, descartando las observaciones más antiguas a medida que se incorporan nuevas muestras. En cambio, el enfoque expansivo conserva todos los datos históricos disponibles y amplía progresivamente el conjunto de entrenamiento en cada iteración. En este trabajo se ha optado por el enfoque expansivo, ya que disponer de una mayor cantidad de datos históricos suele resultar beneficioso para modelos financieros, especialmente en contextos con alta variabilidad y ruido.

La variable objetivo y_t se define como una etiqueta binaria que indica si el activo aumentará de precio durante los próximos h días. Durante la fase de entrenamiento esta variable está disponible porque forma parte del proceso supervisado de aprendizaje, pero debe eliminarse completamente en la fase de inferencia, donde únicamente se utilizan características conocidas en el instante actual.

Uno de los aspectos más delicados en este tipo de problemas es evitar fugas temporales sutiles. Un ejemplo frecuente consiste en aplicar técnicas de normalización utilizando el conjunto completo de datos antes de dividir entre entrenamiento y validación. Aunque pueda parecer una operación inocua, esto permite que el modelo conozca indirectamente la distribución futura de las variables, introduciendo información no disponible en un escenario real. Para evitar este problema, el escalador

se ajusta exclusivamente con los datos de entrenamiento y posteriormente se aplica sobre los conjuntos de validación y prueba.

El método clásico de validación cruzada en K particiones tampoco resulta adecuado para series temporales. Este procedimiento divide aleatoriamente el conjunto de datos ignorando el orden cronológico de las observaciones, permitiendo que el modelo se entrene con muestras futuras respecto a las empleadas para validar. Para evitar este problema se utiliza una variante denominada validación cruzada purgada en K particiones (López de Prado, 2018). Este método mantiene el orden temporal de los datos y permite trabajar con múltiples ventanas de validación sin mezclar información futura con datos pasados. Además, se introduce un periodo de embargo de un día entre entrenamiento y validación con el objetivo de reducir correlaciones excesivas entre muestras consecutivas, medida especialmente importante para el horizonte de un día.

La validación final del modelo se realiza mediante un procedimiento de evaluación progresiva sobre datos fuera de muestra. El entrenamiento comienza con una primera ventana de 750 sesiones bursátiles, equivalentes a aproximadamente tres años de mercado. Posteriormente, se añade un día de embargo y una ventana de prueba de 63 sesiones. En las siguientes iteraciones, la ventana de entrenamiento se incrementa en pasos trimestrales. Este procedimiento permite simular de forma más realista el comportamiento del modelo en producción, ya que en cada iteración únicamente se utiliza información disponible hasta ese momento. El horizonte temporal de un día genera un total de 70 ventanas de evaluación, mientras que para el horizonte de cinco días se obtienen 66 ventanas.

Evaluación

La evaluación del sistema se divide en dos niveles complementarios. En primer lugar, se analiza el rendimiento desde una perspectiva de aprendizaje automático, utilizando métricas estándar de clasificación. En segundo lugar, se traslada el problema al contexto financiero, donde se evalúa el comportamiento de la estrategia en condiciones más realistas de mercado.

Evaluación en el contexto del aprendizaje automático

En este nivel se mide la capacidad predictiva del modelo como problema de clasificación binaria. La precisión equilibrada se emplea como métrica principal de optimización, ya que corrige el posible desbalance entre clases y proporciona una medida equilibrada del rendimiento global. El coeficiente de correlación de Matthews (MCC) complementa este análisis al considerar los cuatro elementos de la matriz de confusión, ofreciendo una medida robusta incluso en escenarios con clases desbalanceadas. Por su parte, el ROC-AUC evalúa la capacidad del modelo para discriminar entre clases positivas y negativas a través de todos los umbrales de decisión posibles.

La elección de estas métricas resulta especialmente relevante en el contexto financiero, donde predecir correctamente tanto los días favorables como los desfavorables tiene la misma importancia. Un modelo que simplemente prediga movimientos alcistas de forma sistemática podría obtener resultados aparentemente aceptables sin aportar información útil desde el punto de vista operativo.

Para evaluar si la precisión equilibrada media de cada modelo es estadísticamente superior al azar, se aplica una prueba t de una muestra, utilizando como observaciones las puntuaciones obtenidas en las distintas ventanas de evaluación temporal. Adicionalmente, se emplean contrastes pareados para comparar el rendimiento de los modelos entre sí.

Evaluación en el contexto financiero

Una vez validado el rendimiento predictivo, los resultados se trasladan a un entorno de simulación de trading con el objetivo de analizar su impacto económico real. La rentabilidad acumulada mide el beneficio total durante el periodo de evaluación, mientras que la rentabilidad bruta representa el

beneficio acumulado antes de considerar costes de transacción. La pérdida máxima cuantifica la mayor caída experimentada desde un máximo hasta un mínimo consecutivo. El ratio de Sharpe (Sharpe, 1966) permite analizar la rentabilidad ajustada al riesgo, relacionando el exceso de retorno obtenido con la volatilidad de la estrategia.

Con el fin de contextualizar el rendimiento del modelo, se incluyen varias estrategias de referencia: (i) la estrategia de *comprar y mantener*, que consiste en mantener la posición inicial durante todo el periodo actuando como referencia pasiva del comportamiento del mercado; (ii) el *clasificador aleatorio*, que genera señales de manera aleatoria para comprobar si el modelo aporta información predictiva real más allá del azar; y (iii) una estrategia ingenua de *momentum*, que predice que la dirección futura del activo coincidirá con la tendencia observada durante los últimos cinco días de cotización.

3.7 Declaración de uso de IA

Se han utilizado herramientas de IA generativa (OpenAI, 2025) para revisar textos y código.

Capítulo 4

Resultados experimentales

Este capítulo presenta los resultados obtenidos en la evaluación experimental. Se organiza en cuatro secciones: resultados de clasificación en los conjuntos de prueba y contrastes estadísticos entre modelos, análisis de importancia de variables, resultados de la simulación financiera, y una discusión de los resultados que relaciona ambas dimensiones de la evaluación.

4.1 Resultados predictivos de los modelos

La Tabla 3 recoge el rendimiento medio en los conjuntos de prueba de los modelos evaluados para los horizontes de predicción de uno y cinco días. Los valores de $\pm$ corresponden al error estándar de la media entre ventanas de evaluación. Dado que las ventanas de evaluación en el esquema de ventana expansiva no se solapan, las observaciones pueden considerarse aproximadamente independientes.

Tabla 3. Métricas de los modelos en los conjuntos de prueba, ordenadas de mayor a menor precisión equilibrada. H hace referencia al horizonte de predicción en días. La columna "Significativo" indica si la precisión equilibrada es estadísticamente superior al 50% según la prueba t de una muestra ($\alpha = 0,05$).

Modelo	Precisión equilibrada (%)	ROC AUC	MCC	Significativo
RF (H1)	53.16 $\pm$ 3.28	0.5448	0.0649	Sí
GRU (H1)	52.74 $\pm$ 3.06	0.5431	0.0564	Sí
XGB (H1)	52.55 $\pm$ 3.28	0.5381	0.0541	Sí
LSTM (H1)	52.34 $\pm$ 2.64	0.5383	0.0486	Sí
RF (H5)	51.76 $\pm$ 4.64	0.5301	0.0399	Sí
LSTM (H5)	51.68 $\pm$ 3.64	0.5245	0.0371	Sí
GRU (H5)	51.58 $\pm$ 3.59	0.5261	0.0356	Sí
XGB (H5)	50.70 $\pm$ 3.46	0.5250	0.0145	No
Markov (H5)	50.10 $\pm$ 1.18	0.5048	0.0016	No
Markov (H1)	49.92 $\pm$ 0.92	0.4974	-0.0016	No

Los resultados sugieren la existencia de una señal predictiva débil pero detectable en la dirección del IBEX 35. En términos de precisión equilibrada, todos los modelos superan el umbral del azar —a excepción del modelo de Markov en ambos horizontes, que se mantiene prácticamente en el 50% (49,92% y 50,10%, respectivamente)—. La prueba *t* de una muestra confirma que las diferencias del modelo de Markov no son estadísticamente significativas, lo que indica que la información contenida en los estados discretos del retorno pasado no es suficiente para predecir de forma sistemática la dirección futura del mercado.

En el horizonte de un día, los cuatro modelos restantes muestran una precisión equilibrada significativamente superior al azar ($p < 0,001$ en todos los casos), con valores superiores al 52%.

Aunque las diferencias absolutas respecto al 50% son reducidas, Random Forest alcanza el mejor desempeño (53,16%), seguido de GRU y XGBoost. Este resultado es coherente con el benchmark de la literatura, que sitúa el rendimiento de modelos de aprendizaje automático en predicción diaria de renta variable entre el 52% y el 55% de precisión equilibrada (Krauss et al., 2017). El ROC-AUC y el MCC refuerzan este patrón: los valores de MCC, siempre inferiores a 0,07, confirman que la magnitud del efecto es reducida en términos absolutos, consistente con la hipótesis del mercado eficiente en su forma débil (Fama, 1970).

Para el horizonte de cinco días, el rendimiento general se deteriora moderadamente. Random Forest, LSTM y GRU mantienen su significación estadística, si bien con mayor variabilidad entre ventanas. XGBoost no puede rechazar la hipótesis nula a nivel $\alpha = 0,05$ en el horizonte de cinco días, lo que sugiere que su ventaja predictiva es predominantemente de corto plazo.

Comparación pareada entre modelos

El contraste de una muestra frente a 0,5 permite evaluar si cada modelo supera el azar, pero no si un modelo es significativamente mejor que otro. Para abordar esta cuestión se realizaron contrastes t pareados entre todos los pares de modelos, utilizando las puntuaciones en los conjuntos de prueba como observaciones. Las Tablas 4 y 5 resumen los resultados en forma de matrices de victorias para los horizontes H1 y H5, respectivamente, donde "Mejor" indica que el modelo de fila supera significativamente al modelo de columna ($p < 0,05$, bilateral), y "Ns" indica ausencia de diferencia significativa. No se realizaron comparaciones entre H1 y H5 porque los conjuntos de prueba se basan en ventanas temporales distintas, sin correspondencia uno-a-uno, por lo que no es posible aplicar contrastes pareados entre horizontes.

Tabla 4. Matriz de comparaciones pareadas (prueba *t* bilateral) para $H=1$. "Mejor": el modelo fila supera significativamente al modelo columna; "Ns": diferencia no significativa.

	Markov (H1)	RF (H1)	XGB (H1)	GRU (H1)	LSTM (H1)
Markov (H1)	-	Peor	Peor	Peor	Peor
RF (H1)	Mejor	-	Mejor	Ns	Mejor
XGB (H1)	Mejor	Peor	-	Ns	Ns
GRU (H1)	Mejor	Ns	Ns	-	Ns
LSTM (H1)	Mejor	Peor	Ns	Ns	-

Tabla 5. Matriz de comparaciones pareadas (prueba *t* bilateral) para $H=5$.

	Markov (H5)	RF (H5)	XGB (H5)	GRU (H5)	LSTM (H5)
Markov (H5)	-	Peor	Ns	Peor	Peor
RF (H5)	Mejor	-	Mejor	Ns	Ns
XGB (H5)	Ns	Peor	-	Ns	Peor
GRU (H5)	Mejor	Ns	Ns	-	Ns
LSTM (H5)	Mejor	Mejor	Ns	Ns	-

En $H1$ se observa un patrón relativamente más claro de separación entre modelos. Random Forest destaca como el modelo más consistente dentro de los métodos de aprendizaje automático, superando de forma significativa a Markov, XGBoost y LSTM, mientras que su ventaja frente a GRU no resulta estadísticamente concluyente. XGBoost muestra un comportamiento intermedio, con mejoras frente a Markov pero sin diferencias robustas respecto a modelos neuronales recurrentes. GRU y LSTM, por su parte, no presentan ventajas sistemáticas frente a los modelos basados en árboles en este horizonte

En $H5$, las diferencias se atenúan. Random Forest mantiene su posición como uno de los modelos más competitivos, superando significativamente a Markov y XGBoost, pero sin diferencias estadísticamente significativas frente a GRU y LSTM. En general, los modelos tienden a converger en rendimiento, lo que indica una mayor dificultad del problema predictivo a horizontes más largos y una reducción de la separación estadística entre enfoques. En este contexto, las matrices reflejan que no existe un modelo dominante universal, sino más bien regiones de equivalencia estadística entre varios de ellos, especialmente entre métodos no lineales.

Para la simulación financiera se han seleccionado Random Forest en ambos horizontes ($H1$ y $H5$). Aunque las comparaciones pareadas muestran que las diferencias con respecto a otros modelos no son siempre estadísticamente significativas, Random Forest es el modelo que alcanza la mayor precisión equilibrada media en ambos horizontes (53,16% en $H1$ y 51,76% en $H5$).

4.2 Importancia de variables

La importancia de variables de los modelos Random Forest y XGBoost se ha calculado midiendo la reducción media de impureza de Gini ponderada por el número de muestras que pasan por cada nodo en todos los árboles del conjunto. Este método proporciona una estimación de la contribución relativa de cada característica al rendimiento predictivo del modelo de árbol, y se puede calcular directamente a partir de la estructura interna del modelo.

La Figura 6 muestra la importancia relativa de las características en los modelos de árbol para los horizontes H1 y H5.




Figura 6. Importancia relativa de las características en los modelos de árbol (Random Forest y XGBoost) para los horizontes H1 y H5.

El patrón es consistente en ambos horizontes: las variables más influyentes son la variación estandarizada del VIX estadounidense y métricas de volatilidad y actividad del S&P 500, seguidas de indicadores de amplitud del mercado IBEX 35. Este resultado indica que el estado del mercado americano —su nivel de tensión y actividad— constituye la señal más informativa para predecir la dirección del IBEX 35. La preponderancia de estas señales sobre los indicadores técnicos individuales de cada acción sugiere que la dirección del mercado español está fuertemente condicionada por el contexto macroeconómico global, y que los modelos han aprendido a explotar esta dependencia estructural.

A diferencia de los modelos de árbol, cuya importancia de variables es directamente interpretable a partir de la estructura interna del modelo, las arquitecturas recurrentes como LSTM y GRU presentan un carácter inherentemente más opaco. No obstante, dado que todos los modelos comparten el mismo conjunto de variables de entrada, las variables identificadas como más influyentes por los modelos de árbol pueden proporcionar una referencia útil sobre qué información podría estar siendo aprovechada también por los modelos neuronales, si bien no es posible establecer una correspondencia directa sin un análisis específico de interpretabilidad.

4.3 Resultados de la simulación financiera

El período de prueba está comprendido entre el 1 y el 31 de mayo. La simulación parte de una cartera inicial de 100.000 euros y sigue una estrategia exclusivamente *long-only*. Cuando el modelo genera una señal positiva, se abre una posición en la apertura de la sesión siguiente ($t+1$); en cambio, las señales negativas se ignoran y no dan lugar a ninguna operación. Todas las posiciones tienen el mismo peso dentro de la cartera. En las estrategias RF H1, clasificador aleatorio y momentum, las posiciones se cierran al cierre de la misma sesión en la que se ejecuta la orden ($t+1$), mientras que en RF H5 se mantienen abiertas durante cinco sesiones bursátiles y se liquidan al cierre de $t+5$. La estrategia de comprar y mantener permanece invertida durante todo el período de evaluación. Para aproximar las condiciones reales de mercado, se aplica un coste de transacción de 10 puntos básicos por operación, que tiene en cuenta tanto comisiones como la horquilla entre precio de compra y venta del activo. Dado que el clasificador aleatorio presenta una elevada variabilidad, sus resultados corresponden al promedio de 1.000 muestras bootstrap independientes. Estos resultados deben interpretarse con cautela, ya que se obtienen sobre un único mes de datos y, por tanto, constituyen una evidencia meramente descriptiva y de tamaño muestral reducido.

Tabla 6. Resultados de la simulación de trading para distintas estrategias durante el período de prueba (1 de mayo – 1 de junio de 2026). Los valores de rentabilidad son acumulados en el período.

Estrategias	Rentabilidad bruta (%)	Rentabilidad (%)	Pérdida máxima (%)	Ratio Sharpe
RF (H1)	-0.50%	-3.26%	-4.21%	-7.793
RF (H5)	+2.88%	+2.07%	-3.18%	3.072
Comprar y mantener	+3.27%	+3.27%	-2.93%	1.908
Clasificador aleatorio	+3.03%	-0.81%	-3.28%	-0.970
Momentum	+1.92%	-1.88%	-4.31%	-2.008

Se observa en la Tabla 6 que la estrategia de Comprar y mantener y el modelo RF H5 son las únicas que logran retornos positivos netos, con un +3.27% y un 2.07%, respectivamente. Asimismo, RF (H5) destaca por registrar el Ratio Sharpe más elevado (3.072) y la menor pérdida máxima (-3.18%) entre los modelos predictivos, consolidándose como una estrategia eficiente en términos de riesgo-retorno.

La estrategia de RF H1, en cambio, presenta una rentabilidad bruta ligeramente negativa (-0.50%), que se acentúa una vez aplicados los costes de transacción (-3.26%). El clasificador aleatorio y el momentum, aunque parten de una rentabilidad bruta positiva, también se ven afectados por los costes operacionales.

Los costes de transacción tienen un alto impacto en las estrategias de alta frecuencia. La operativa diaria sobre una cartera diversificada de 30 activos implica un número elevado de operaciones que erosionan completamente el pequeño exceso de rentabilidad bruta de los modelos. El horizonte de cinco días, al igual que la estrategia de comprar y mantener, reduce sustancialmente la rotación de la cartera, manteniendo posiciones abiertas durante más tiempo y amortizando mejor los costes fijos por operación sobre un retorno acumulado mayor.

En conjunto, estos resultados son coherentes con la hipótesis planteada anteriormente: gran parte de la señal predictiva identificada por los modelos proviene de variables relacionadas con el mercado estadounidense. Dado que esta información se conoce tras el cierre de Wall Street, es probable que el mercado español incorpore parte de ella antes de la apertura del IBEX 35 del día siguiente. Como consecuencia, la capacidad predictiva observada durante el entrenamiento puede no traducirse

completamente en una ventaja explotable en condiciones reales de mercado, particularmente en estrategias de corto horizonte como RF H1.

4.4 Discusión de los resultados

Los modelos de aprendizaje automático detectan una señal predictiva débil pero estadísticamente significativa en la dirección de los activos del IBEX 35. Esa señal solo se traduce en rentabilidad real cuando se gestiona adecuadamente la frecuencia operativa y, con ella, el impacto de los costes de transacción.

Desde la perspectiva estadística, Random Forest H1 y H5 lideran el ranking de precisión equilibrada en sus respectivos horizontes. No obstante las diferencias entre los modelos de aprendizaje automático resultan en su mayoría no significativas, lo que indica que, en el contexto de un mercado desarrollado, las distintas arquitecturas convergen hacia un límite común de capacidad predictiva.

Desde la perspectiva financiera, los resultados muestran que la rentabilidad final está más condicionada por la estructura operativa de la estrategia que por el modelo en sí. En particular, los horizontes más cortos resultan más sensibles a los costes de transacción, mientras que enfoques de menor rotación permiten una mejor captación de la señal y una mayor estabilidad en los retornos.

Cabe recalcar, por último, que el período de simulación es corto y los resultados pueden estar condicionados por el régimen de mercado específico de ese período..

Capítulo 5

Conclusiones

Este trabajo ha abordado el problema de la predicción de dirección del mercado bursátil español mediante técnicas de aprendizaje automático, integrando los resultados en un sistema automatizado de extremo a extremo. A continuación se presentan las principales conclusiones derivadas del estudio.

Sobre la capacidad predictiva de los modelos. Los resultados obtenidos demuestran que los modelos de aprendizaje automático basados en árboles de decisión (Random Forest, XGBoost) y redes neuronales recurrentes (GRU, LSTM) poseen una capacidad predictiva estadísticamente superior al azar sobre la dirección del IBEX 35. Random Forest es el modelo con mejor rendimiento en el horizonte de un día, con una precisión equilibrada de $53,16\% \pm 3,28$, resultado coherente con el rango de 52-55% reportado en la literatura para predicción diaria de renta variable (Krauss et al., 2017). El modelo de Markov, por el contrario, no supera el umbral del azar en ningún horizonte, lo que indica que la información contenida en los estados discretos del retorno pasado no es suficiente para predecir de forma sistemática la dirección futura del mercado. La mayor parte de las diferencias entre los modelos de aprendizaje automático no son estadísticamente significativas en los contrastes pareados, lo que sugiere que en el margen de rendimiento disponible en un mercado eficiente todas las arquitecturas convergen hacia un límite similar.

Sobre la naturaleza de la señal predictiva. El análisis de importancia de variables revela que la señal predictiva identificada por los modelos proviene principalmente de variables macroeconómicas externas, en particular de la variación del VIX y de métricas de actividad del S&P 500. Este hallazgo sugiere que la dirección del mercado español está condicionada en mayor medida por el contexto macroeconómico global que por los indicadores técnicos individuales de cada acción, resultado que es consistente con la literatura sobre integración y transmisión de información entre mercados internacionales. Sin embargo, esta dependencia implica también que la señal puede ser parcialmente anticipada por el propio mercado antes de la apertura de la sesión bursátil, lo que limita su explotabilidad práctica.

Sobre la brecha entre capacidad estadística y rentabilidad real. La evaluación financiera evidencia con claridad la diferencia entre significancia estadística y explotabilidad económica. A pesar de que el modelo presenta una precisión equilibrada estadísticamente significativa, la operativa diaria sobre una cartera diversificada genera un número elevado de transacciones cuyos costes de fricción terminan por eliminar completamente el reducido margen predictivo. La estrategia de comprar y mantener supera en rentabilidad neta a todas las estrategias activas durante el período analizado, lo que es coherente con la hipótesis del mercado eficiente en su forma débil (Fama, 1970). Este resultado recuerda una limitación fundamental del aprendizaje automático en finanzas: la significancia estadística es condición necesaria pero no suficiente para la rentabilidad práctica.

Sobre el sistema construido. Más allá de los resultados predictivos, este trabajo demuestra la viabilidad de construir un sistema de análisis financiero automatizado y completo —desde la ingesta de datos hasta la ejecución de operaciones— utilizando exclusivamente herramientas gratuitas y de código abierto. La arquitectura desarrollada integra un pipeline de datos en la nube, múltiples modelos de aprendizaje automático, una página web con predicciones actualizadas diariamente, un boletín informativo automatizado y un bot de trading conectado a un bróker real. Esta integración constituye en sí misma una contribución de carácter ingenieril, demostrando que es posible construir infraestructura de análisis financiero de calidad sin incurrir en costes económicos elevados.

Limitaciones del estudio. El trabajo presenta diversas limitaciones que deben tenerse en cuenta al interpretar los resultados. En primer lugar, el universo de activos está sujeto a sesgo de supervivencia,

ya que únicamente se han incluido los componentes actuales del IBEX 35. En segundo lugar, el período de simulación financiera es reducido, por lo que los resultados pueden estar condicionados por el régimen de mercado específico de ese período. En tercer lugar, los modelos no incorporan las noticias financieras recopiladas como variables de entrada, lo que constituye una fuente de información cualitativa potencialmente relevante que no ha sido explotada. Por último, los costes de transacción utilizados son fijos y no modelizan el impacto de mercado de órdenes de tamaño elevado.

En definitiva, este trabajo confirma que los mercados financieros desarrollados presentan ineficiencias débiles y explotables estadísticamente mediante modelos de aprendizaje automático, pero que la traducción de estas señales en rentabilidad real es muy difícil debido a los costes de transacción, la rapidez con que el mercado incorpora información disponible públicamente y la baja magnitud del efecto predictivo. El valor del sistema desarrollado reside no solo en sus métricas predictivas, sino en la demostración de que un sistema de análisis financiero completo puede construirse con recursos accesibles y metodología rigurosa.

Capítulo 6

Trabajo futuro

En una línea de trabajo futura, uno de los aspectos más relevantes consiste en ampliar de forma significativa la base de datos utilizada, incorporando un mayor volumen de información histórica de noticias. El incremento del horizonte temporal, abarcando períodos de varios años, permitiría capturar mejor la evolución de los patrones informativos y su relación con los movimientos del mercado. En este contexto, la integración de noticias en el proceso de predicción adquiere un papel especialmente relevante, ya que posibilitaría incorporar información cualitativa que complementa los datos estrictamente financieros.

En cuanto al tratamiento de la información textual, en lugar de limitarse a una clasificación simplificada del sentimiento asociado a las noticias, se plantea la posibilidad de utilizar representaciones vectoriales de los textos. Este enfoque permite capturar matices semánticos más ricos y relaciones más complejas entre documentos, lo que podría traducirse en una mejora en la calidad de las señales generadas.

Asimismo, resulta pertinente ampliar el conjunto de variables explicativas mediante la inclusión de indicadores macroeconómicos adicionales, como la tasa de empleo, la inflación u otras métricas de actividad económica. Este tipo de variables pueden aportar una visión más global del entorno financiero, mejorando la capacidad del modelo para adaptarse a diferentes regímenes de mercado.

Por otro lado, se abre la puerta a explorar nuevas fuentes de información o combinaciones de indicadores menos convencionales que puedan identificar señales con mayor capacidad explicativa y potencial predictivo. Muchas de las variables utilizadas en este trabajo son indicadores técnicos clásicos ampliamente seguidos por el mercado, lo que puede limitar su capacidad de generar ventaja si son anticipados por otros participantes.

Desde una perspectiva de gestión del riesgo y la operativa, sería interesante incorporar reglas de gestión dinámica del tamaño de las posiciones en función de la volatilidad, así como definir zonas de entrada y salida del mercado basadas en la confianza del modelo. Estos enfoques, propios de la gestión de carteras, pueden contribuir tanto a mejorar la rentabilidad ajustada al riesgo como a dotar al sistema de mayor robustez en distintos regímenes de mercado.

Finalmente, la calibración de probabilidades del modelo —mediante técnicas como la escala de Platt o la regresión isotónica— podría mejorar la utilidad de las probabilidades generadas para el dimensionamiento de posiciones, ya que actualmente estas probabilidades no pueden interpretarse en sentido estadístico estricto.

Bibliografía

Amihud, Y. (2002). Illiquidity and stock returns: Cross-section and time-series effects. *Journal of Financial Markets*, 5(1), 31-56. [https://doi.org/10.1016/S1386-4181\(01\)00024-6](https://doi.org/10.1016/S1386-4181(01)00024-6)

Bloomberg L.P. (s. f.). Bloomberg Terminal. Bloomberg Professional Services. Recuperado el 15 de mayo de 2026, de <https://professional.bloomberg.com/products/bloomberg-terminal/>

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., y Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.^a ed.). John Wiley & Sons.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>

Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)* (pp. 785-794). Association for Computing Machinery. <https://doi.org/10.1145/2939672.2939785>

Cho, K., van Merriënboer, B., Gülçehre, Ç., Bahdanau, D., Bougares, F., Schwenk, H., y Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. En *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (pp. 1724-1734). Association for Computational Linguistics. <https://aclanthology.org/D14-1179/>

Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383-417. <https://doi.org/10.1111/j.1540-6261.1970.tb00518.x>

Fischer, T., y Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), 654-669. <https://doi.org/10.1016/j.ejor.2017.11.054>

GitHub. (s. f.). GitHub Actions documentation. Recuperado el 15 de mayo de 2026, de <https://docs.github.com/actions>

Groq. (s. f.). GroqCloud documentation. Recuperado el 15 de mayo de 2026, de <https://console.groq.com/docs/overview>

Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357-384. <https://doi.org/10.2307/1912559>

Hochreiter, S., y Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>

Interactive Brokers. (s. f.). IB Gateway. Recuperado el 15 de mayo de 2026, de <https://www.interactivebrokers.com/en/trading/ibgateway-stable.php>

Krauss, C., Do, X. A., y Huck, N. (2017). Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2), 689-702. <https://doi.org/10.1016/j.ejor.2016.10.031>

Lo, A. W., y MacKinlay, A. C. (1988). Stock market prices do not follow random walks: Evidence from a simple specification test. *The Review of Financial Studies*, 1(1), 41-66. <https://doi.org/10.1093/rfs/1.1.41>

López de Prado, M. (2018). *Advances in financial machine learning*. John Wiley & Sons.

OpenAI. (2025, 5 de agosto). gpt-oss-120b & gpt-oss-20b model card. OpenAI. <https://openai.com/index/gpt-oss-model-card/>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., VanderPlas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830. <https://www.jmlr.org/papers/v12/pedregosa11a.html>

Aroussi, R. (s. f.). yfinance: Download market data from Yahoo! Finance's API. GitHub. Recuperado el 15 de mayo de 2026, de <https://github.com/ranaroussi/yfinance>

Sharpe, W. F. (1966). Mutual fund performance. *The Journal of Business*, 39(1, Part 2), 119-138. <https://doi.org/10.1086/294846>

Supabase. (s. f.). Supabase: The Postgres development platform. Recuperado el 15 de mayo de 2026, de <https://supabase.com>

TradingView. (s. f.). TradingView: Track all markets. Recuperado el 15 de mayo de 2026, de <https://www.tradingview.com>

Yahoo Finance. (s. f.). Yahoo Finance: Stock market live, quotes, business & finance news. Recuperado el 15 de mayo de 2026, de <https://finance.yahoo.com>

Apéndice

Repositorio de código

El repositorio del proyecto está disponible en el siguiente enlace:

De La Haya, A. (2026). Análisis, predicción y ejecución automatizada de inversiones en empresas del IBEX 35. Recuperado el 6 de junio de 2026, de https://github.com/alexhayadela/10tothe6_TFG_2025_AlexDeLaHaya

El fichero *README.md* contiene información detallada sobre el cronograma de los entregables del proyecto, las instrucciones necesarias para la instalación y puesta en marcha del entorno, los requisitos técnicos y dependencias y la guía de uso y ejecución de las distintas funcionalidades desarrolladas.

Página Web

El enlace web correspondiente a la *Figura 4* puede consultarse en:

De La Haya, A. (2026). Análisis, predicción y ejecución automatizada de inversiones en empresas del IBEX 35. Recuperado el 6 de junio de 2026, de https://alexhayadela.github.io/10tothe6_TFG_2025_AlexDeLaHaya/docs/

Contacto

Para cualquier consulta relacionada con el proyecto, puede contactar a través del siguiente correo electrónico: alexdlhaya@gmail.com

Asimismo, aquellas personas interesadas en recibir el boletín diario de seguimiento del proyecto pueden solicitar su inclusión enviando un mensaje a la dirección de contacto indicada anteriormente.